

INSTITUCIÓN UNIVERSITARIA PASCUAL BRAVO

Facultad de Ingeniería

Asignatura: Metodología de la Investigación

EduCurator AI: desarrollo y evaluación en curso de un sistema agéntico para la curación asistida de contenidos educativos

Proyecto de investigación en curso

Versión 1 — Protocolo de investigación y reporte de avance

Autores

Mateo Correa Restrepo

Anyi Daniela Manco Henao

Julián Pico Garzón

Jhonatan Alexander Méndez Roa

Estado del documento. Este documento es un *protocolo de investigación acompañado de un reporte de avance*. El artefacto tecnológico (EduCurator) ya fue construido y se encuentra en estado de MVP funcional; la fase de evaluación experimental está en curso. **No se reportan resultados experimentales obtenidos:** las secciones de la Parte VII enuncian resultados *esperados y por obtener*, no evidencia recogida.

Medellín, Antioquia — Colombia

2026

Resumen

El material de apoyo de un curso universitario se acumula a lo largo de varios semestres hasta formar corpus en los que conviven versiones redundantes, afirmaciones contradictorias y contenidos desactualizados. Mantener la coherencia de ese corpus es una tarea de curación que recae sobre el docente y que la literatura sobre carga académica sitúa entre las actividades poco visibles en los modelos institucionales de asignación de trabajo (Kenny & Fluck, 2023). La incorporación de inteligencia artificial generativa no resuelve el problema por sí sola: la evidencia sistemática disponible indica que la IA generativa *redistribuye* la carga docente más de lo que la reduce, porque añade trabajo de revisión, verificación y juicio sobre sus propias salidas (Su et al., 2026).

Este documento presenta **EduCurator**, un sistema de curación asistida de documentación de cursos que combina recuperación de evidencia sobre el corpus del propio curso, detectores de redundancia e inconsistencia, un subagente con herramientas, evidencia estructurada y revisión humana obligatoria antes de cualquier publicación. La investigación se formula bajo *Design Science Research* (Hevner et al., 2004; Peffers et al., 2007), con punto de entrada en la actividad de diseño y desarrollo: el artefacto ya existe como MVP funcional y el trabajo pendiente es su demostración y evaluación controlada.

El documento cumple dos funciones simultáneas. Como **protocolo**, define la pregunta de investigación, las proposiciones, las variables operacionalizadas, el benchmark con defectos plantados y controles negativos, la batería de configuraciones de comparación (heurísticas, recuperación dispersa, recuperación densa, canalización híbrida y sistema completo), las métricas de detección, *grounding*, calibración y carga de trabajo, y el plan de análisis estadístico. Como **reporte de avance**, delimita qué está construido, qué evidencia técnica existe hoy y qué permanece abierto.

Alcance de lo que aquí se afirma. Este documento *no* reporta resultados experimentales. No se afirma que EduCurator detecte inconsistencias con una precisión determinada, que reduzca el tiempo de curación, que sus puntajes de confianza estén calibrados ni que los docentes lo perciban como útil. Esas afirmaciones requieren la evidencia que la Parte V está diseñada para producir y que todavía no se ha recogido.

Palabras clave: curación de contenidos educativos; generación aumentada por recuperación; agentes basados en modelos de lenguaje; *human-in-the-loop*; trazabilidad; *design science research*; carga de trabajo docente.

Abstract

Course support material accumulates over successive semesters into corpora where redundant versions, contradictory statements and outdated content coexist. Keeping such a corpus coherent is a curation task that falls on the instructor and that the academic-workload literature places among the activities institutional workload models tend to overlook (Kenny & Fluck, 2023). Introducing generative AI does not solve this by itself: systematic evidence indicates that generative AI *redistributes* teaching workload more than it reduces it, since it adds review, verification and judgement work over its own outputs (Su et al., 2026).

This document presents **EduCurator**, an assisted curation system for course documentation that combines evidence retrieval over the course corpus, redundancy and inconsistency detectors, a tool-using sub-agent, structured evidence, and mandatory human review before any publication. The research is framed as *Design Science Research* (Hevner et al., 2004; Peffers et al., 2007) with a design- and development-centred entry point: the artefact already exists as a functional MVP, and what remains is its demonstration and controlled evaluation.

The document works both as a **protocol** — research question, propositions, operationalised variables, a benchmark with planted defects and negative controls, a ladder of comparison configurations, detection, grounding, calibration and workload metrics, and a statistical analysis plan — and as a **progress report** that states what has been built, what technical evidence exists today, and what remains open. **No experimental results are reported here.**

Keywords: educational content curation; retrieval-augmented generation; LLM agents; human-in-the-loop; traceability; design science research; academic workload.

Índice

Resumen	i
Abstract	ii
I Contexto y problema	1
1. Introducción	1
1.1. Por qué el artefacto no es el resultado	1
1.2. Qué pregunta abre el problema	2
1.3. Función y organización del documento	2
1.4. Criterio de lectura	3
2. Contexto del problema	3
2.1. La carga docente y sus componentes invisibles	3
2.2. La expectativa sobre la IA generativa y lo que la evidencia muestra . .	4
2.3. Qué significa que un recurso educativo tenga calidad	4
2.4. Qué automatiza hoy el aseguramiento de calidad	5
2.5. El estado de la investigación sobre IA en educación superior	6
3. Problema de investigación	6
3.1. Delimitación del objeto	6
3.2. Manifestaciones del problema	7
3.3. La tensión que constituye el problema de investigación	8
3.4. Lo que el problema no incluye	8
4. Justificación	9
4.1. Justificación académica: un espacio poco sintetizado y poco riguroso . .	9
4.2. Justificación tecnológica: por qué esta combinación y no otra	10
4.3. Justificación práctica: el riesgo de trasladar el costo al docente	10
4.4. Justificación normativa: qué exige un uso responsable	11

4.5. Justificación institucional	12
5. Referencias	13

Parte I

Contexto y problema

1 Introducción

Este documento reporta el estado de una investigación en curso sobre **EduCurator**, un sistema de curación asistida de documentación de cursos universitarios. La investigación tiene una particularidad que conviene declarar desde el principio: el artefacto tecnológico *ya existe*. Hay un producto mínimo viable (MVP) funcional que implementa la arquitectura propuesta y que puede ejecutar el flujo completo de curación sobre un corpus real. Lo que no existe todavía es la evidencia empírica sobre su desempeño.

Esa asimetría define la naturaleza del documento. No se trata de un informe de resultados ni de la memoria de un desarrollo de software, sino de un **protocolo de investigación acompañado de un reporte de avance**: establece qué se quiere averiguar sobre el artefacto, con qué diseño experimental, con qué instrumentos y bajo qué criterios de análisis; y, en paralelo, delimita con precisión qué está construido y qué permanece abierto.

1.1 Por qué el artefacto no es el resultado

Un error frecuente en los proyectos de ingeniería con componente investigativo es presentar el sistema construido como si fuera el hallazgo de la investigación. Una funcionalidad implementada demuestra *capacidad técnica*: que el sistema puede ejecutar una operación. Una evaluación demuestra *desempeño*: con qué exactitud, bajo qué condiciones y frente a qué alternativas. Son afirmaciones de distinto tipo y requieren distinta evidencia.

La metodología de *Design Science Research* permite sostener esta distinción sin contradicción metodológica. Peffers et al. (2007) admiten explícitamente puntos de entrada distintos al ciclo de investigación, entre ellos uno *centrado en el diseño y desarrollo*, en el que el artefacto precede a la formalización del problema y de la evaluación. Hevner et al. (2004) exigen, a cambio, que la contribución se demuestre mediante métodos de evaluación rigurosos: el artefacto por sí solo no constituye conocimiento. Este documento

se sitúa exactamente en ese punto: el diseño y el desarrollo están hechos; la demostración y la evaluación son el trabajo que falta.

1.2 Qué pregunta abre el problema

La curación de material docente — comparar versiones, detectar duplicados, identificar contradicciones, reconocer lo que quedó desactualizado — es una tarea que crece con el volumen del corpus y que rara vez se completa de forma sistemática. La expectativa razonable sería que la inteligencia artificial generativa la aliviara. La evidencia sistemática disponible advierte contra esa expectativa: en una revisión PRISMA de 30 estudios empíricos, Su et al. (2026) encuentran que solo el 20 % reporta reducción de la carga docente, el 16,7 % reporta aumento y el 63,3 % reporta un efecto mixto. Su conclusión es que la IA generativa produce una transformación estructural más que una reducción: «the key change brought about by GenAI is not whether work becomes “less”, but how workload is redistributed» Su et al., 2026, p. 11.

El mecanismo que describen es directamente pertinente aquí: la IA ahorra tiempo en tareas procedimentales, pero añade trabajo de revisión de calidad de sus salidas, verificación de hechos y juicio sobre lo que propone. Es decir, un asistente de curación que proponga cambios sin evidencia verificable traslada al docente el costo de comprobarlos y puede terminar siendo una fuente neta de trabajo. Ese es el riesgo de diseño que EduCurator intenta atacar y, a la vez, la razón por la que su evaluación no puede limitarse a medir tiempo.

1.3 Función y organización del documento

El documento está organizado en siete partes:

- La **Parte I** sitúa el problema, lo delimita y lo justifica.
- La **Parte II** revisa el conocimiento existente en las ocho líneas bibliográficas del proyecto y formula la brecha de investigación.
- La **Parte III** enuncia la pregunta, los objetivos — separando los de investigación de los de desarrollo —, las proposiciones, las variables operacionalizadas y el modelo conceptual que las vincula.
- La **Parte IV** describe el artefacto: qué propone, qué implementa y qué no se sabe aún sobre él.
- La **Parte V** define la metodología de evaluación: benchmark, configuraciones de comparación, ablaciones, instrumentos, métricas y plan de análisis.

- La **Parte VI** reporta el estado de avance, la evidencia técnica disponible y lo pendiente.
- La **Parte VII** enuncia resultados esperados, contribuciones esperadas y el cronograma de validación.

1.4 Criterio de lectura

Para mantener separadas afirmaciones de distinto estatus epistémico, cada enunciado sustantivo del documento corresponde a una de cuatro categorías:

- (A) **Lo que la literatura ya demuestra**, con su fuente.
- (B) **Lo que el MVP actualmente implementa**, verificable en el repositorio.
- (C) **Lo que la investigación propone evaluar**, con su diseño.
- (D) **Lo que todavía no se conoce** y constituye el objeto de la investigación.

Advertencia metodológica

Ningún enunciado de este documento afirma que EduCurator mejore la curación, reduzca el tiempo docente, elimine las alucinaciones o supere a alternativa alguna. Esas serían afirmaciones de la categoría (A) sin fuente que las respalde, o afirmaciones de la categoría (C) presentadas como si ya fueran (A). Donde el texto se refiere al comportamiento del sistema, lo hace en términos de lo que *implementa* o de lo que *se propone medir*.

2 Contexto del problema

El problema que aborda esta investigación se sitúa en la intersección de tres hechos documentados: la carga de trabajo docente y su composición real, la definición de calidad de un recurso educativo y los límites de lo que hoy se automatiza, y el estado de la investigación sobre IA en educación superior.

2.1 La carga docente y sus componentes invisibles

La preparación y el mantenimiento de material de curso forman parte de un conjunto de actividades que los modelos institucionales de asignación de carga tienden a subestimar. Kenny y Fluck (2023) validaron una herramienta holística de estimación de carga académica (AWET) con 39 académicos de 21 universidades australianas, contrastando la carga estimada con la asignada nominalmente. La carga promedio ponderada resultó del

132 % de una carga completa (unas 2252 horas anuales); 24 de los 39 participantes superaban el 110 % y 11 superaban el 150 %. Solo 3 tenían un perfil efectivamente equilibrado entre docencia, investigación y servicio, frente a 18 según su asignación nominal. Las actividades de coordinación, liderazgo, administración, supervisión y adaptación de la enseñanza en línea no estaban contempladas en los modelos institucionales.

Advertencia metodológica

Kenny y Fluck (2023) no miden la carga específica de curar o mantener documentación de cursos, y su «validación» es cualitativa: no reportan indicadores psicométricos. La fuente sirve para argumentar que existe trabajo docente de apoyo sistemáticamente no contabilizado, *no* para cuantificar el tiempo que un docente dedica a la curación.

2.2 La expectativa sobre la IA generativa y lo que la evidencia muestra

La hipótesis implícita de que automatizar equivale a reducir trabajo no se sostiene con la evidencia disponible. La revisión sistemática de Su et al. (2026) — 30 estudios empíricos, cribado doble con $\kappa = 0,845$ en título y resumen y $\kappa = 0,851$ en texto completo, calidad evaluada con MMAT 2018 — documenta una redistribución: la IA generativa ahorra tiempo en preparación de materiales, borradores de retroalimentación y textos administrativos, pero añade revisión de la calidad de las salidas, verificación de hechos, juicio ético y monitoreo de integridad académica.

Un hallazgo de esa revisión condiciona directamente el diseño de evaluación de este proyecto: las conclusiones de los estudios primarios dependen de *cómo* midan la carga. Los que la operacionalizan como eficiencia (tiempo de tarea) tienden a encontrar reducción; los que la operacionalizan como intensificación (adaptación, supervisión, responsabilidad) tienden a encontrar aumento. Los autores advierten que «Future research that relies only on time-efficiency indicators may underestimate the invisible work intensification brought about by GenAI» Su et al., 2026, p. 10. De ahí que la Parte V contemple tiempo *y* carga percibida como medidas complementarias, no intercambiables.

2.3 Qué significa que un recurso educativo tenga calidad

La calidad de un recurso educativo es multidimensional, pero la literatura converge en que la exactitud del contenido es la dimensión dominante. El *Learning Object Review Instrument* (LORI 1.5), cuyos fundamentos expone Leacock y Nesbit (2007), define nueve dimensiones — calidad del contenido, alineación con objetivos, retroalimentación y

adaptación, motivación, diseño de la presentación, usabilidad, accesibilidad, reusabilidad y cumplimiento de estándares — y sitúa la primera por encima de las demás: «A learning resource is of little or no use if it is well designed in all other respects but its content is inaccurate or misleading» Leacock y Nesbit, 2007, p. 45. Los autores señalan además que los estudiantes desarrollan comprensiones incompletas que reproducen los errores de los materiales, y que la presencia de información específica de una instancia — fechas de entrega, nombres del instructor — degrada la reusabilidad de un recurso; ambos puntos anticipan dos de las clases de defecto que este proyecto busca detectar: la contradicción y la desactualización.

El estudio de Xie et al. (2018) sobre 1200 reseñas de recursos digitales elaboradas por docentes aporta un dato metodológicamente relevante: los revisores comentan con más frecuencia las virtudes que los defectos de un recurso. La revisión humana, por sí sola, tiende a subdetectar problemas. En sentido complementario, Tabares Morales et al. (2017), al aplicar un modelo de evaluación por capas a 46 objetos de aprendizaje de la Federación de Repositorios de Objetos de Aprendizaje de Colombia, documentan el caso inverso: un objeto con buenos indicadores automáticos — basados en metadatos — obtuvo valoraciones muy bajas de expertos y usuarios. Ninguna de las dos vías basta por separado.

Lectura conjunta de las tres fuentes. La evaluación automática detecta lo que es formalizable (completitud de metadatos, enlaces rotos, similitud entre textos); la revisión humana juzga la sustancia pero subdetecta defectos y no escala. La combinación de ambas es la posición que esta investigación adopta, y coincide con la recomendación de Clements et al. (2015) tras revisar 82 artículos sobre repositorios educativos: «Expert review might be not the most economical approach, but it seems to be needed in order to evaluate the substance of the resources in the repository» Clements et al., 2015, p. 6.

2.4 Qué automatiza hoy el aseguramiento de calidad

La revisión de Clements et al. (2015) identifica quince instrumentos específicos de aseguramiento de calidad en repositorios educativos: revisión por pares, calificaciones, herramientas tipo LORI, recomendadores, comentarios, etiquetado social, marcado de problemas (enlaces rotos, contenido inapropiado), especificación de autoría y licencias, redes de confianza y pruebas automáticas de metadatos. El alcance de lo automatizado en ese panorama se limita a **metadatos, enlaces y recomendaciones**: ningún instrumento verifica el contenido en sí. Los autores observan además que los instrumentos colaborativos dependen de una comunidad activa y que, en educación, la motivación para calificar y comentar es menor que en comercio electrónico — una restricción que

se agrava en el corpus de un curso individual, donde la comunidad es, en el límite, una persona.

2.5 El estado de la investigación sobre IA en educación superior

Dos revisiones separadas por cinco años coinciden en dónde está y dónde no está la investigación. Zawacki-Richter et al. (2019) mapearon 146 artículos sobre aplicaciones de IA en educación superior: solo 13 (8,9 %) tienen como primer autor a alguien de Educación, el 73,3 % emplea métodos cuantitativos — sobre todo cuasiexperimentales, con estudios piloto que no controlan el efecto novedad —, y solo 2 de 146 (1,4 %) reflexionan críticamente sobre implicaciones éticas. En su tipología, la curación de materiales aparece en 3 estudios y el apoyo al docente en el diseño de la enseñanza, en otros 3.

Bond et al. (2024) confirman el patrón en una revisión terciaria de 66 revisiones centradas en educación superior (cribado doble con $\kappa = 0,89$ y $\kappa = 0,85$): solo 5 revisiones (7,6 %) mencionan el uso de IA para evaluar materiales de aprendizaje — y casi siempre midiendo tiempo de uso en plataforma, no el contenido —, y la curación de materiales aparece en 3 (4,5 %). En cuanto a rigor, la puntuación media de calidad metodológica fue de 6,57 sobre 10 y «A noticeable 65 % of reviews are critically low to medium quality» Bond et al., 2024, p. 34; el 51,5 % no reporta acuerdo entre revisores. Entre los desafíos más citados figura el **desplazamiento de la autoridad** hacia la IA (22,6 %), y entre los vacíos, la necesidad de mayor rigor y variedad metodológica (36,4 %) junto con el llamado a evaluar el efecto de las herramientas sobre el aprendizaje y las personas, y no solo su exactitud técnica.

Advertencia metodológica

Ninguna de estas dos revisiones evalúa la eficacia de herramienta alguna: son mapeos de literatura. Que la curación de materiales aparezca en pocas revisiones indica escasa *síntesis* sobre el tema, no necesariamente escasa investigación primaria. La brecha que se formula en la Parte II se apoya en esa evidencia con esa salvedad explícita.

3 Problema de investigación

3.1 Delimitación del objeto

El objeto de esta investigación no es el repositorio institucional ni el recurso educativo abierto, sino el **corpus documental de un curso**: el conjunto de guías, apuntes,

presentaciones, lecturas, listados de preguntas frecuentes y evaluaciones que un docente produce, edita y reutiliza a lo largo de varios semestres. Esta delimitación importa porque desplaza el problema respecto de la literatura de calidad de repositorios revisada en la sección 2.3:

- La unidad de análisis no es el recurso aislado, sino la **relación entre documentos**. Un documento puede ser individualmente correcto y, aun así, contradecir a otro del mismo corpus.
- No existe una comunidad de usuarios que ejerza control colaborativo de calidad. El aseguramiento recae sobre una persona.
- El corpus es **cerrado y conocido**, lo que hace posible verificar cada afirmación contra documentos concretos en lugar de contra el conocimiento general del mundo.

3.2 Manifestaciones del problema

Sobre ese corpus se observan cuatro manifestaciones, que esta investigación trata como clases distintas y no como un único fenómeno de «desorden»:

1. **Redundancia.** El mismo contenido aparece en varios documentos con redacciones distintas. Dispersa la referencia autorizada y multiplica los puntos que hay que actualizar cuando algo cambia.
2. **Inconsistencia o contradicción.** Dos documentos del corpus afirman cosas incompatibles: un valor numérico, una definición, un procedimiento, un plazo, un criterio de evaluación.
3. **Desactualización.** Un contenido que fue correcto deja de serlo porque cambió el estándar, la versión de una tecnología o la normativa, y permanece en circulación. Incluye el caso que Leacock y Nesbit (2007) señalan como degradación de la reusabilidad: información específica de una instancia pasada (fechas, nombres, cupos).
4. **Ausencia de evidencia localizable.** No hay un punto desde el cual consultar el corpus y establecer de qué documento y de qué fragmento proviene una afirmación.

La distinción entre las clases 2 y 4 no es retórica. La literatura de inferencia en lenguaje natural la trata como una distinción de clase: Koreeda y Manning (2021) en inferencia a nivel documental sobre contratos, Thorne et al. (2018) en extracción y verificación de hechos, y Gubelmann et al. (2024) en su revisión de conjuntos de

datos de NLI separan *contradice* de *no hay información suficiente*. En estas tareas la contradicción es la clase más difícil y la clase neutral la peor reconocida por los modelos. Un sistema que colapse ambas categorías en «alerta» produce un tipo de error que el docente no puede interpretar: no distingue «esto se contradice con aquello» de «no encontré con qué comparar esto».

3.3 La tensión que constituye el problema de investigación

Asistir la curación con modelos de lenguaje introduce el riesgo que la propia tarea pretende reducir. Huang et al. (2025) distinguen la alucinación de *factualidad* — contradecir o inventar hechos del mundo — de la de *fidelidad* — apartarse del contexto proporcionado o contradecirlo — y documentan que la recuperación aumentada no resuelve el problema: «Despite being designed to mitigate LLM hallucinations, retrieval-augmented LLMs can still produce hallucinations» Huang et al., 2025, p. 26.

El punto crítico para este proyecto está en las causas que identifican. Entre las fuentes de alucinación en sistemas RAG figuran las **fuentes con información incorrecta o desactualizada**, la fragmentación inadecuada del texto, el contexto ruidoso y los conflictos de conocimiento. En un corpus de curso con contradicciones, *los propios documentos son esa fuente de riesgo*: el sistema recupera evidencia inconsistente y puede fundamentar sobre ella una sugerencia incorrecta. A ello se suma que los modelos no reconocen bien sus límites de conocimiento y producen falsedades con confianza, lo que vuelve insuficiente cualquier señal de confianza que no haya sido contrastada con la tasa real de acierto.

De esta tensión surge el problema:

Problema de investigación. Un sistema que asista la curación de un corpus de curso debe operar sobre un material que puede ser internamente inconsistente, usando un componente generativo que puede producir afirmaciones no fundamentadas y señales de confianza que pueden no corresponder a su tasa de acierto. Se desconoce *en qué medida* una arquitectura que combina recuperación, detectores, razonamiento con herramientas, evidencia estructurada y revisión humana detecta las inconsistencias reales de ese corpus, *qué componentes* de esa combinación explican su comportamiento, y *con qué efecto* sobre el trabajo del docente.

3.4 Lo que el problema no incluye

Para evitar que el objeto se desdibuje, se excluyen explícitamente:

- La **verificación factual contra el mundo**. El criterio de corrección es la

consistencia con el corpus del curso y, cuando aplique, con las fuentes externas que el docente autorice, no la verdad general de una afirmación.

- La **evaluación del aprendizaje**. No se mide si un corpus más coherente mejora resultados de aprendizaje; esa relación excede el alcance y requiere un diseño distinto.
- La **calidad pedagógica** en las dimensiones de LORI ajenas al contenido (motivación, diseño de la presentación, accesibilidad). El sistema no juzga si un material es didácticamente adecuado.
- La **sustitución del juicio docente**. La decisión sobre qué se conserva, qué se corrige y qué se descarta permanece fuera del sistema por diseño, no por limitación técnica.

4 Justificación

4.1 Justificación académica: un espacio poco sintetizado y poco riguroso

La sección 2.5 documenta dos hechos que, combinados, definen el valor académico de esta investigación. El primero es de *cobertura*: en la revisión terciaria de Bond et al. (2024), la evaluación de materiales de aprendizaje con IA aparece en el 7,6 % de las revisiones y la curación de materiales en el 4,5 %; en el mapeo previo de Zawacki-Richter et al. (2019), la curación de materiales aparecía en 3 de 146 artículos. Cuando el tema aparece, se aborda midiendo el uso de la plataforma, no el contenido.

El segundo es de *rigor*: el 65 % de las revisiones analizadas por Bond et al. (2024) tiene calidad metodológica de crítica a media, el 51,5 % no reporta acuerdo entre revisores, y los autores piden explícitamente evaluar el efecto de las herramientas sobre las personas y no solo su exactitud técnica. Diez años antes, Zawacki-Richter et al. (2019) ya señalaban estudios piloto con resultados «preliminares positivos» que no controlan el efecto novedad.

La contribución académica que se pretende, entonces, no es «aplicar IA a la educación», sino producir sobre un caso concreto el tipo de evidencia que el campo reclama: un benchmark con verdad de referencia anotada y acuerdo entre anotadores reportado, configuraciones de comparación que permitan atribuir el desempeño a componentes identificables, y un estudio con docentes que mida efecto sobre las personas además de exactitud técnica.

4.2 Justificación tecnológica: por qué esta combinación y no otra

Cada componente de la arquitectura responde a una limitación documentada, no a una preferencia de implementación:

- La **recuperación de evidencia** responde a que el criterio de corrección en este problema es la consistencia con el corpus del curso. Sin recuperación, el sistema dependería de la memoria paramétrica del modelo, que no es verificable contra los documentos del docente (Lewis et al., 2020).
- Los **detectores explícitos** responden a que la contradicción es la clase más difícil de las tareas de inferencia documental (Gubelmann et al., 2024; Koreeda & Manning, 2021) y a que el aseguramiento automatizado disponible en repositorios educativos no llega al contenido, solo a metadatos y enlaces (Clements et al., 2015).
- La **evidencia estructurada** responde a las causas de alucinación en sistemas RAG identificadas por Huang et al. (2025), entre ellas las fuentes incorrectas o desactualizadas; la atribución explícita de origen es una de las mitigaciones que el propio survey señala.
- La **revisión humana** responde a que la evaluación automática por sí sola no basta para juzgar la sustancia de un recurso (Clements et al., 2015; Tabares Morales et al., 2017), y a que la revisión humana por sí sola subdetecta defectos (Xie et al., 2018).

Advertencia metodológica

Que cada componente responda a una limitación documentada justifica *su inclusión en el diseño*; no demuestra que aporte valor en la práctica. Determinar cuáles de estos componentes explican efectivamente el comportamiento del sistema es precisamente el objeto de las ablaciones descritas en la Parte V.

4.3 Justificación práctica: el riesgo de trasladar el costo al docente

La justificación práctica de este proyecto no puede formularse como «ahorrar tiempo al docente», porque esa afirmación es exactamente la que Su et al. (2026) muestran problemática. Se formula de otra manera: si un asistente de curación propone cambios sin evidencia localizable, el docente debe reconstruir por su cuenta la justificación de cada propuesta, y ese trabajo de verificación es la forma específica de intensificación que la revisión sistemática documenta.

El diseño que aquí se evalúa apuesta por reducir ese costo de verificación haciendo

que cada propuesta llegue acompañada del fragmento que la sustenta. La apuesta es falsable: si el tiempo de revisión y la carga percibida no difieren de una condición de revisión sin asistencia, la apuesta no se sostiene. El diseño experimental de la Parte V está construido para que ese resultado sea posible y reportable.

4.4 Justificación normativa: qué exige un uso responsable

Dos marcos de referencia convergen en requisitos que este proyecto adopta como restricciones de diseño y como objetos de medición.

El *AI Risk Management Framework* del National Institute of Standards and Technology (2023) sitúa la validez y la fiabilidad como base de las demás características de una IA confiable, y atraviesa todas ellas con transparencia y rendición de cuentas. Varias de sus subcategorías se traducen directamente en obligaciones para este proyecto: documentar los límites de conocimiento del sistema y cómo se supervisan sus salidas (MAP 2.2), documentar los procesos de supervisión humana (MAP 3.5), documentar conjuntos de prueba, métricas y herramientas de verificación (MEASURE 2.1), demostrar validez y fiabilidad declarando los límites de generalización (MEASURE 2.5) y evaluar seguridad y resiliencia (MEASURE 2.7). El marco recomienda además recoger datos sobre la frecuencia y las razones con que los humanos anulan las salidas de la IA, lo que en este proyecto se traduce en registrar los motivos de rechazo como dato de investigación y no solo como funcionalidad.

La guía de Miao y Holmes (2023) para IA generativa en educación e investigación establece que la agencia humana no debe cederse en decisiones de alto impacto, que las aplicaciones deben validarse ética y pedagógicamente antes de su adopción institucional, y que la IA generativa, por rápida que sea como fuente de información, no puede constituir una fuente autorizada de conocimiento (Miao & Holmes, 2023, p. 26). Sobre el apoyo al docente, la guía es explícita en que los diseñadores humanos del currículo deben verificar el conocimiento factual y la pertinencia de lo que la IA sugiera (Miao & Holmes, 2023, p. 31).

Consecuencia de diseño. Estos marcos no son un apartado ético decorativo: determinan que la revisión humana previa a la publicación sea una restricción arquitectónica no negociable, que la trazabilidad de cada decisión sea un requerimiento y no una característica opcional, y que los límites de generalización del sistema deban declararse junto con cualquier resultado que se reporte.

4.5 Justificación institucional

El proyecto se desarrolla en un contexto donde la evidencia sobre calidad de recursos educativos tiene antecedentes locales: Tabares Morales et al. (2017) aplican su modelo de evaluación por capas a la Federación de Repositorios de Objetos de Aprendizaje de Colombia. Trabajar sobre corpus de cursos en español añade además una condición que la literatura técnica revisada no cubre: la evidencia sobre recuperación y sobre jueces automáticos está dominada por el inglés — las tareas de recuperación de MTEB son exclusivamente en inglés (Muennighoff et al., 2023) y los jueces entrenados de ARES pierden concordancia con la anotación humana al cambiar de idioma (Saad-Falcon et al., 2024) —, lo que obliga a validar con datos en español los componentes que se adopten. Esta restricción se desarrolla en la Parte V como una amenaza a la validez que el diseño debe controlar, no como un supuesto que pueda darse por resuelto.

5 Referencias

- Bond, M., Khosravi, H., De Laat, M., Bergdahl, N., Negrea, V., Oxley, E., Pham, P., Chong, S. W., & Siemens, G. (2024). A meta systematic review of artificial intelligence in higher education: A call for increased ethics, collaboration, and rigour. *International Journal of Educational Technology in Higher Education*, 21, Artículo 4. <https://doi.org/10.1186/s41239-023-00436-z>
- Clements, K., Pawlowski, J., & Manouselis, N. (2015). Open educational resources repositories literature review – towards a comprehensive quality approaches framework [[VERIFICAR] El PDF consultado es la versión article in press; volumen y páginas tomados de la versión publicada]. *Computers in Human Behavior*, 51(B), 1098-1106. <https://doi.org/10.1016/j.chb.2015.03.026>
- Gubelmann, R., Katis, I., Niklaus, C., & Handschuh, S. (2024). Capturing the varieties of natural language inference: A systematic survey of existing datasets and two novel benchmarks. *Journal of Logic, Language and Information*, 33, 21-48. <https://doi.org/10.1007/s10849-023-09410-4>
- Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research [[VERIFICAR] DOI de JSTOR]. *MIS Quarterly*, 28(1), 75-105. <https://doi.org/10.2307/25148625>
- Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2025). A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *ACM Transactions on Information Systems*, 43(2), Artículo 42. <https://doi.org/10.1145/3703155>
- Kenny, J., & Fluck, A. E. (2023). Life at the academic coalface: Validation of a holistic academic workload estimation tool. *Higher Education*, 86, 507-526. <https://doi.org/10.1007/s10734-022-00912-x>
- Koreeda, Y., & Manning, C. D. (2021). Contractnli: A dataset for document-level natural language inference for contracts [[VERIFICAR] El PDF consultado es arXiv:2110.01799v1]. *Findings of the Association for Computational Linguistics: EMNLP 2021*, 1907-1919. <https://doi.org/10.18653/v1/2021.findings-emnlp.164>
- Leacock, T. L., & Nesbit, J. C. (2007). A framework for evaluating the quality of multimedia learning resources. *Educational Technology & Society*, 10(2), 44-59.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks [[VERIFICAR] El PDF consultado es arXiv:2005.11401v4]. *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 9459-9474.

- Miao, F., & Holmes, W. (2023). *Guidance for generative ai in education and research*. UNESCO. <https://doi.org/10.54675/EWZM9535>
- Muennighoff, N., Tazi, N., Magne, L., & Reimers, N. (2023). Mteb: Massive text embedding benchmark. *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, 2014-2037. <https://doi.org/10.18653/v1/2023.eacl-main.148>
- National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (ai rmf 1.0)* (NIST AI 100-1) (En parte de la literatura se cita como Tabassi (2023); se adopta la forma institucional). U.S. Department of Commerce. <https://doi.org/10.6028/NIST.AI.100-1>
- Peppers, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45-77. <https://doi.org/10.2753/MIS0742-1222240302>
- Saad-Falcon, J., Khattab, O., Potts, C., & Zaharia, M. (2024). Ares: An automated evaluation framework for retrieval-augmented generation systems. *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 338-354. <https://doi.org/10.18653/v1/2024.naacl-long.20>
- Su, F., Beh, W. F., & Cheah, K. S. L. (2026). Efficiency or intensification? a systematic review of generative ai and academic workload in higher education. *Acta Psychologica*, 268, Artículo 107353. <https://doi.org/10.1016/j.actpsy.2026.107353>
- Tabares Morales, V., Duque Méndez, N. D., & Ovalle Carranza, D. A. (2017). Modelo por capas para evaluación de la calidad de objetos de aprendizaje en repositorios. *Revista Electrónica de Investigación Educativa*, 19(3), 33-50. <https://doi.org/10.24320/redie.2017.19.3.1128>
- Thorne, J., Vlachos, A., Christodoulopoulos, C., & Mittal, A. (2018). Fever: A large-scale dataset for fact extraction and verification. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, 809-819. <https://doi.org/10.18653/v1/N18-1074>
- Xie, K., Di Tosto, G., Chen, S.-B., & Vongkulluksn, V. W. (2018). A systematic review of design and technology components of educational digital resources [[VERIFICAR] El PDF consultado es el manuscrito aceptado, sin paginación final]. *Computers & Education*, 127, 90-106. <https://doi.org/10.1016/j.compedu.2018.08.011>
- Zawacki-Richter, O., Marín, V. I., Bond, M., & Gouverneur, F. (2019). Systematic review of research on artificial intelligence applications in higher education –

where are the educators? *International Journal of Educational Technology in Higher Education*, 16, Artículo 39. <https://doi.org/10.1186/s41239-019-0171-0>